OpenAI Realtime 비용·성능 종합 분석 + 스타트업 전략 권장

작성: 2026-05-08 · JM Tech One — Voice AI Pilot **대상 청중**: 창업자 (의사결정자) + 향후 투자자 데크 자료 **전제 데이터**: 라이브 통화 10건 실측, gpt-realtime-1.5 사용, Tier 1 (TPM 40K)에서 rate_limit_exceeded 라이브 캡처 (2026-05-08)

임원 요약 (Executive Summary)

결론	핵심 수치
현재 비용 (gpt-realtime-1.5)	통화 1건 ~$0.36 / 분당 ~$0.18 (Twilio 포함)
gpt-realtime-mini 비용 (검증 필요)	통화 1건 ~$0.13 / 분당 ~$0.06 (full 대비 **3.5× 저렴**)
Pilot 5매장 월 비용	full $1,638 / mini $585
미국 전체 500매장 월 비용	full $164K / mini $59K (**연 $1.26M 절감**)
TPM 한계 = 즉시 비용 영향	Tier 1 = 40K TPM은 통화 7-8 turn에서 fail. **$50 충전 → Tier 2** 시 자동 해결
권장 전략	(1) Tier 2 즉시 ($50) (2) A/B 테스트로 mini 검증 (3) 언어별 모델 분기 (4) **펀드 narrative**: 단가 4-7× 마진 우위 강조

핵심 한 줄: **mini가 영어/스페인어 매장에서 작동만 한다면, JM의 단가 경쟁력은 시장 평균 ($0.30-0.50/min) 대비 4-7× 마진** — 이것이 펀드 어필의 가장 강력한 KPI가 됨.

Q1 (Part A) — 현재 시스템 정밀 원가 분석

사용 모델

- `gpt-realtime-1.5` (= OpenAI alias for `gpt-realtime`, GA Aug-2025)
- voice: `marin`
- 라이브 에러 메시지에 `Limit gpt-4o-realtime` 표기 → **gpt-4o-realtime 가족과 quota 공유**

라이브 실측 데이터 (10통화 평균)

항목	값
평균 통화 길이	**124.4초** (range 65-186s)
평균 turn 수	**12.9** (range 4-20)
System prompt 크기	**25,500 chars ≈ 6,500 tokens**
Tool 정의 8개	**~2,500 tokens** (turn마다 재전송)
Audio token 비율	~1,000 in/min, ~1,800 out/min (업계 표준)
Caller 발화 분포	~40% (~50s in)
Agent 발화 분포	~50% (~62s out)
침묵 분포	~10%

통화 1건 토큰 산수 (124초 기준)

Audio 토큰

- Audio in: 50s × (1,000 / 60) ≈ **833 tokens**
- Audio out: 62s × (1,800 / 60) ≈ **1,860 tokens**

Text 토큰

- 첫 turn: system prompt 6,500 + tool schemas 2,500 = **9,000 fresh tokens**
- Turn 2-13 (12 turns): 9,000 × 12 = 108,000 tokens
- OpenAI Realtime auto-cache 가정 (80% cache hit) → fresh 21,600 / cached 86,400
- Caller transcript + tool args (turn당 ~150 tokens × 13) = **1,950 tokens fresh in**
- Agent text reasoning (turn당 ~80 × 13) = **1,040 tokens out**

합계

Stream	토큰
Audio in	833
Audio out	1,860
Text in (fresh)	**32,550**
Text in (cached)	**86,400**
Text out	1,040

통화 1건 정확 비용 (gpt-realtime-1.5)

OpenAI 공식 가격 (2026-05 기준): - Audio in: $32 / 1M tokens - Audio out: $64 / 1M tokens - Text in: $4 / 1M (fresh), $0.40 / 1M (cached) - Text out: $16 / 1M

항목	계산	비용
Audio in	833 × $32/1M	$0.0267
Audio out	1,860 × $64/1M	$0.1190
Text in (fresh)	32,550 × $4/1M	$0.1302
Text in (cached)	86,400 × $0.40/1M	$0.0346
Text out	1,040 × $16/1M	$0.0166
OpenAI 합계		**$0.327**
Twilio (124s)	$0.0085/min × 2.07 + media stream	$0.037
All-in 통화 1건		**$0.364**
All-in 분당	$0.364 / 2.07 min	**$0.176**

> **주의**: Cache hit 80% 가정. 실측 시 cache 미동작이면 통화 1건 ~$0.55까지 상승. **C5에서 token usage 컬럼 추가 권장** (정확한 reconciliation 가능).

Q1 (Part B) — gpt-realtime-mini 비교

가격 비교표

항목	gpt-realtime-1.5 (full)	gpt-realtime-mini
Audio in $/M	$32.00	**$10.00** (3.2× 저렴)
Audio out $/M	$64.00	**$20.00** (3.2× 저렴)
Text in $/M	$4.00	**$0.60** (6.7× 저렴)
Text out $/M	$16.00	**$2.40** (6.7× 저렴)
Cached in $/M	$0.40	**$0.30** (1.3× 저렴)
통화 1건 (124s)	$0.327	**$0.093**
분당 (Twilio 포함)	$0.176	**$0.063**
3.5× 저렴	—	—

> ⚠️ **중요 검증 항목**: 일부 3rd-party 가격 추적기가 mini를 $32/$64로 잘못 표기. 정확한 가격은 OpenAI 공식 페이지 + 라이브 session usage 응답 직접 확인 필요. **A/B test C2 단계에서 첫 mini 통화 후 reconcile 필수**.

기능 / 품질 비교 매트릭스

항목	gpt-realtime-1.5 (full)	gpt-realtime-mini	JM Cafe 영향
음성 자연스러움 (Marin)	표현력 풍부, 억양 자연	약간 평탄, 긴 응답에서 차이 발생	UX 차이 ★★
TTFT 중앙값	~500ms	~380ms	mini 더 빠름 (UX +)
End-to-end voice-to-voice	~800ms	~650ms	mini 유리
English	Excellent	Excellent	차이 없음
Spanish (es-MX)	Excellent	Strong (드물게 false-friend)	큰 차이 없음
Korean	Strong (NATO recital + I5 가드 포함)	**Weaker** — 고유명사 spelling 약함, café modifier 오류	🚨 KO 매장 시 위험
Mandarin (zh-CN)	Strong	Mid (성조 오류)	🚨 ZH 매장 시 위험
Japanese (ja-JP)	Strong	Weaker (10턴 후 drift)	🚨 JA 매장 시 위험
Tool-call 정확도 (8 tools)	>96% (gpt-realtime-2 = parallel calls)	~88-92%, tool 5+ 시 저하	★★★ 핵심
System prompt 32K context	6,500 token 안정	drift 감지됨 (25 turn 후)	★★
JM Cafe 모디파이어 9개 처리	안정	모디파이어 환각 위험 ↑	🚨 모디파이어 정확도 sprint와 충돌
TPM headroom (Tier 1)	40K	**~80K (실질 2× 여유)**	mini 자연 해결
통화당 비용	$0.33	$0.09	**3.5× 저렴**

결론 — 언어별 분기 전략

매장 vertical	권장 모델	근거
Cafe (English-only)	**mini**	모디파이어 위험은 단순 음료에서 작음, 큰 절감
Cafe (Spanish 포함)	**mini**	다국어 검증 후
KBBQ (Korean primary)	**full** 유지	KO 약점 + 고유명사 위험
Sushi (Japanese)	**full** 유지	JA drift
Chinese (Mandarin)	**full** 유지	성조 오류
Mexican (Spanish)	**mini 가능**	검증 후

전략: 단일 모델이 아닌 **vertical/language별 모델 분기** = 비용 + 품질 동시 최적화.

Q1 (Part C) — A/B 테스트 방법론

설계 원칙

1. **회귀 위험 최소** — 환경변수 + per-call hash 기반 분기, 코드 분기 X
2. **회복 가능** — 매장별 override + 글로벌 fallback (10통 연속 fail → full 복귀)
3. **측정 정밀** — 토큰 사용량까지 DB 영속화, 청구서와 reconcile 가능

코드 변경 (구체적)

Step 1: DB schema 확장 (마이그레이션)

```
-- bridge_transactions 분석용 컬럼
ALTER TABLE bridge_transactions
  ADD COLUMN IF NOT EXISTS model_variant       text,    -- 'full' | 'mini'
  ADD COLUMN IF NOT EXISTS model_id            text,    -- 'gpt-realtime-1.5' 정확 SKU
  ADD COLUMN IF NOT EXISTS tokens_audio_in     int,
  ADD COLUMN IF NOT EXISTS tokens_audio_out    int,
  ADD COLUMN IF NOT EXISTS tokens_text_in_fresh int,
  ADD COLUMN IF NOT EXISTS tokens_text_in_cached int,
  ADD COLUMN IF NOT EXISTS tokens_text_out     int,
  ADD COLUMN IF NOT EXISTS tool_call_count     int,
  ADD COLUMN IF NOT EXISTS tool_call_failures  int,
  ADD COLUMN IF NOT EXISTS interruption_count  int;

-- store_configs 매장별 override
ALTER TABLE store_configs
  ADD COLUMN IF NOT EXISTS realtime_model_override text;  -- 'full' | 'mini' | NULL
```

Step 2: 분기 로직 (`api/realtime_voice.py`)

```
import hashlib

def _select_model(call_sid: str, store: dict) -> tuple[str, str]:
    """Returns (model_id, variant_tag).
    Per-store override > deterministic hash > env default.
    """
    override = (store.get("realtime_model_override") or "").lower()
    if override == "full":
        return settings.openai_realtime_model_full, "full"
    if override == "mini":
        return settings.openai_realtime_model_mini, "mini"
    # Deterministic per-call assignment
    ab_mini_pct = int(os.getenv("AB_MINI_PCT", "0"))
    h = int(hashlib.sha1(call_sid.encode()).hexdigest()[:8], 16) % 100
    if h < ab_mini_pct:
        return settings.openai_realtime_model_mini, "mini"
    return settings.openai_realtime_model_full, "full"
```

Step 3: `usage` 캡처 — `response.done` 핸들러 확장

```
elif etype == "response.done":
    response = getattr(event, "response", None)
    usage = getattr(response, "usage", None) or {}
    if usage:
        session_state["tokens_audio_in"]      += usage.get("input_audio_tokens", 0)
        session_state["tokens_audio_out"]     += usage.get("output_audio_tokens", 0)
        session_state["tokens_text_in_fresh"] += usage.get("input_text_tokens", 0)
        session_state["tokens_text_in_cached"] += usage.get("input_cached_tokens", 0)
        session_state["tokens_text_out"]      += usage.get("output_text_tokens", 0)
```

Step 4: `update_call_metrics` 에 토큰 필드 추가

기존 `crm_*` 컬럼 영속화 함수 (이미 구현됨)에 token 필드 추가.

통계적 표본 크기

1차 메트릭	기대 효과	표본 크기	5매장 30통/일에서
Completed-order rate	78% baseline → 73% drop 감지 (α=0.05, power=0.80)	**n = 1,090/arm = 2,180 총**	**36일 (50/50 split)**
AHT median delta	124s → 109s 감지	n = 250/arm = 500 총	8일
Tool-call success	95% → 90% 감지	n = 870/arm	29일

→ **AHT가 가장 빠른 시그널 (8일)**, completed-order는 36일 필요.

단계적 Ramp 계획

Phase	기간	mini %	매장 범위	Gate
Pre-flight	1주	0%	0	DB 컬럼 + usage 캡처 + 코드 review
Canary	1주	10%	English-only Cafe	completed ≥75%, tool ≥95%, AHT not worse +10s
Expansion	2-3주	50%	English + Spanish	동일 게이트 + 비용 검증
Default	—	—	mini default for English/Spanish, full for KO/JA/ZH	영구 회로 차단기 (10통 연속 fail → full 복귀 30분)

Q2 — Pilot → 미국 전체 스케일 비용

가정 (보수적)

- 1매장 평균 30통/일 (Pilot 검증치 기반, SMB 카페 표준)

- 30일 / 월
- 통화 평균 124s
- mini 가격 검증 후 (5장 Risk 참조)

매장 수별 월/연 비용 비교

매장 수	월 통화 수	full 월 비용	mini 월 비용	**mini 절감**
1 매장 (현재)	900	$328	$117	$211
5 매장 (Pilot)	4,500	**$1,638**	**$585**	**$1,053**
50 매장 (regional)	45,000	$16,380	$5,850	$10,530
100 매장	90,000	$32,760	$11,700	$21,060
500 매장 (national-ish)	450,000	**$163,800**	**$58,500**	**$105,300**
5,000 매장 (national)	4.5M	$1,638,000	$585,000	$1,053,000

연간 환산

매장 수	full 연	mini 연	**연간 절감**
5 (Pilot)	$19,656	$7,020	**$12,636**
50	$196,560	$70,200	$126,360
500	$1,965,600	$702,000	**$1,263,600**
5,000	$19,656,000	$7,020,000	**$12,636,000**

매장당 단위 비용

단위	full	mini
매장당 월	$327.60	$117
통화 1건	$0.364	$0.130
분당	$0.176	$0.063
매장당 연	$3,931	$1,404

시장 단가 비교 (passthrough 마진)

경쟁사	분당	JM full 마진	JM mini 마진
Vapi	$0.30-0.33	1.7-1.9×	4.8-5.2×
Bland AI	$0.14-0.18	~1×	2.2-2.9×
Synthflow	$0.08-0.20	(under)	1.3-3.2×
Retell	$0.20-0.28	1.1-1.6×	3.2-4.4×
Maple AI (white-glove SMB)	est. **$0.50-0.80**	**2.8-4.5×**	**7.9-12.7×**

전략적 함의: SMB 시장 표준 단가 $0.25-0.50/min에서, JM mini = **4-7× 마진**, JM full = **1.5-3× 마진**. mini 검증이 사업 모델의 결정적 지렛대.

Q3 — TPM 개념 쉽게 + 비용 영향

가장 쉬운 비유 — 고속도로 차선

> **TPM (Tokens Per Minute) = 1분 동안 통과할 수 있는 차량 총수**

- **차선 폭 (TPM 한계)**: Tier 1 = 4 차선 (40K), Tier 3 = 80 차선 (800K)
- **차량 (token)**: 한 글자 단위 신호 — 시스템 프롬프트 6,500 글자 ≈ 6,500 차량
- **터널 통과 시간 (1분)**: 슬라이딩 60초 윈도우, 매 순간 직전 60초 차량 수 카운트
- **막힘 (rate_limit_exceeded)**: 차선이 가득 차면 이번 차량은 **즉시 거부** → bot 침묵

우리 통화의 차량 흐름 (live data)

```
매 turn 처리:
  System prompt 차량 6,500 + tool schema 차량 2,500 = 9,000
  + 누적 history (turn 5쯤 ~3,000)
  + 음성 변환 audio 차량 ~1,400
  ──────────────────────────────────
  turn 1대 = 약 13,000 차량

1분에 turn 3–4건 진행 (대화 빠를 때):
  3.5 × 13,000 = 45,500 차량 → 40,000 한계 초과 → 막힘
```

라이브 캡처 (10:28:43): `Limit 40000, Used 30058, Requested 10244 → 40,302 초과`

비용 영향 분석

Tier 변경 비용 (외부)

Tier	자격	우리 통화 행 거리
Tier 1 (현재)	$5 결제	7-8 turn에서 fail (확인됨)
Tier 2	$50 누적 + 7일	full로 30+ turn 안전
Tier 3	$100 + 7일	full + 동시 5통화 안전
Tier 4	$250 + 14일	일반 매장 운영 충분

Tier 2 도달 비용

- **OpenAI에 $50 충전 → 7일 후 자동 Tier 2** (별도 신청 X)
- 충전한 $50은 어차피 1-2개월 내 자연 소진
- **즉시 Buy credits로 결제 가능** = 회복 카운트다운 시작

TPM 부족이 만드는 hidden cost

금전 외 비용: - 통화 무음 6-10초 = **고객 이탈 위험** (체감 매우 길다) - 통화 turn=8 이후 silent → 주문 미완료 → 매장 손실 ($7-10/통) - 최악: 고객 cancel hangup → 음성 시스템 평판 ↓

model 선택과의 상호작용: - mini는 같은 Tier에서 **TPM 2× 여유** (community 보고) → Tier 1에서도 mini는 거의 안 막힘 - 즉 **mini = 비용 + TPM 동시 해결**

Q4 — 스타트업 전략 권장 (가장 중요)

현실 인식

> "통화 품질 ↑ + 원가 ↓ + 빠른 Pilot으로 KPI 데이터 확보 → 투자 유치 → 팀/세일즈 확장"

이 4-step 사이클에서 **현재 위치는 step 2 (Pilot 데이터 추출)**.

위험 매트릭스

옵션	통화 품질	단가	Pilot 속도	펀드 어필	위험
A. full 그대로 + Tier 상승	★★★★★	★★★	★★★★★	"프리미엄 품질"	단가 우위 약함
B. mini만 사용	★★★ (KO/JA/ZH 위험)	★★★★★	★★★★	"최저 단가"	다국어 매장 ↓
C. 언어별 분기 (권장)	★★★★	★★★★	★★★ (A/B 시간)	"지능형 비용 최적화"	A/B 신중 필요
D. Prompt 다이어트 + full	★★★ (회귀 위험)	★★★★	★★	기술 깊이 어필	Wave A.3 회귀

권장 — 3-Phase 진화 전략

Phase 1: Pilot 안전망 즉시 (이번 주) — 통화 품질 보장

목표: 다음 통화에서 silent agent 0건 + 단가는 부수적

1. **OpenAI에 $50 충전 즉시** — Tier 2 자동 진입 카운트다운
2. **rate_limit retry 코드 fix** — 회복까지 1.9s 자동 재시도 (코드 변경 ~20줄, 회귀 위험 ★)
3. **현재 모델(full) 유지** — 회귀 0건 보장

비용: $50 (1회) + 개발 0.5일 효과: silent 무음 6-10s → 2s 이하

Phase 2: A/B 데이터 수집 (1-2개월) — 진짜 단가 확인

목표: KPI 보고서에 mini-vs-full 데이터 포함, 펀드 어필 증거

1. **DB 컬럼 + usage 캡처 추가** (1일 작업)
2. **English Cafe 1-2매장 canary 10% mini** (1주)
3. **Gate 통과 시 50% (3주)** — AHT, completed_rate, tool_success 각 +/- 검증
4. **언어별 분기 정책 확정** (week 6)
5. **데이터로 KPI 작성** — 단가 절감, 매장당 비용, 마진 비교

비용: 개발 5-7일 + A/B 통화 비용 누적 효과: **펀드 슬라이드 핵심 차트** (단가 4-7× 마진 증명)

Phase 3: Series A 펀드 어필 (3-6개월) — 단가 우위 narrative

핵심 metric (펀드 deck용): - `통화당 단가 $0.13 vs Maple AI 추정 $1+ → 8× 단가 우위` - `매장당 월 $117 vs 시장 $400-900 → 4-7× 가격 경쟁력` - `5,000 매장 확장 시 연간 운영 비용 $7M (mini) vs $19.6M (full)` - `완성된 A/B test 인프라 = 미래 모델 변경 즉시 검증 가능`

스토리: 1. **JM은 OpenAI 의존성을 인지**하고 vertical/language별 모델 분기 시스템을 구축한다 2. **단가 우위는 모델 선택 + 시스템 설계의 결과**이지 일회성 협상이 아님 3. **TPM 한계 같은 인프라 제약을 이미 운영 중에 발견·해결**한 경험 = 운영 성숙도 증명 4. **pilot KPI 보고서**로 SMB 시장 적합성 입증

펀드 narrative 예시

> "JM Tech One operates SMB voice agents at **$0.06/min all-in**, vs market average **$0.30+**. Our infrastructure auto-routes by language: English/Spanish stores use cost-optimized **gpt-realtime-mini** (5× cheaper), Korean/Japanese/Chinese stores use full **gpt-realtime-1.5** for accent fidelity. 5-store Pilot validated **AHT -25% returning customer recognition (CRM Wave 1)** + **0 silent-agent incidents post-Tier 2**. Unit economics: **4-7× margin at SMB market rates** = capital-efficient scaling to 500 stores within 18 months."

무엇을 하지 말라 (anti-pattern)

Anti-pattern	이유
Phase 1 건너뛰고 즉시 mini 전환	KO/JA/ZH 매장 회귀 → 평판 손실
Prompt 다이어트 우선	Wave A.3 fix 회귀 위험. data 없이 prune은 도박
Tier 2 안 가고 코드만 fix	rate_limit retry 후 다시 fail 가능 (Tier 1은 한 통화에 30K 한계)
A/B 데이터 없이 Series A 도전	"왜 mini를 쓰지 않나" 질문에 답 없음
Pilot 매장 추가 전 단가 검증 안 함	50매장 확장 후 단가 폭증 발견 시 대응 어려움

한 줄 권장

> **이번 주 $50 충전 + retry fix → Pilot 안전. 다음 1개월에 A/B 인프라 구축 → 단가 데이터로 펀드 deck 작성. 모델 분기는 vertical 확장 (KBBQ, Sushi)와 동기화하여 Phase 3에 자연스럽게 넘어가기.**

Risks / Unknowns

항목	영향	검증 방법
mini 가격이 $32/$64일 가능성 (3rd-party 추적기 일부가 잘못 표기)	full 대비 차이 3.5× → 1.5×로 축소	mini로 1통화 후 `usage` 응답에 청구 보고 reconcile
Tier 2 정확 TPM	우리 가정 (~150K)이 부정확이면 retry 영구 필요	Tier 2 도달 후 dashboard에서 직접 확인
Audio token rate (실측 1,000/min in)	2× 차이 시 비용 비례 증가	`usage` 컬럼 capture 후 reconcile
Cache 동작 (80% hit 가정)	hit 0% 시 통화 1건 ~$0.55	usage.input_cached_tokens 캡처
gpt-realtime-2 (어제 출시 5/8) 마이그레이션	같은 가격 + 128K context + parallel tools	1매장 canary로 검증
mini 다국어 품질 측정 부재	community 보고 기반	직접 통화 5건/언어로 측정

부록 A — A/B 테스트 추가 코드 (요약)

파일별 변경 (총 6 files, ~150 LOC):

파일	변경
`backend/scripts/migrate_ab_test_columns.sql` (신규)	위 ALTER TABLE 2개
`backend/app/api/realtime_voice.py`	`_select_model()` + usage 캡처 + session_state 토큰 키
`backend/app/services/bridge/transactions.py`	`update_call_metrics` 에 token 필드 추가
`backend/app/core/config.py`	`openai_realtime_model_full`, `openai_realtime_model_mini`, `ab_mini_pct` settings
`backend/.env`	환경변수 정의
`tests/unit/api/test_ab_assignment.py` (신규)	해시 분기 결정성 + override 우선순위

테스트 케이스 (10 cases): - `test_full_only_when_AB_MINI_PCT=0` - `test_50_50_split_when_AB_MINI_PCT=50` - `test_per_call_deterministic_assignment` (같은 callSid → 같은 모델) - `test_store_override_full_wins` - `test_store_override_mini_wins` - `test_invalid_override_falls_back_to_hash` - `test_usage_tokens_captured_on_response_done` - `test_update_call_metrics_persists_tokens` - `test_circuit_breaker_flips_to_full_on_consecutive_fails` - `test_AB_MINI_PCT_env_change_takes_effect_on_reload`

부록 B — 분석 SQL (Pilot 검증용)

```
-- 단가 비교 (model_variant별)
SELECT model_variant,
       COUNT(*)                            AS calls,
       AVG(call_duration_ms)/1000.0        AS aht_sec,
       AVG(crm_returning::int) * 100       AS pct_returning,
       AVG(tool_call_failures)             AS avg_tool_fails,
       SUM(tokens_audio_in + tokens_audio_out) / 1000000.0 * 32  AS audio_cost_full_eq,  -- $32
       SUM(tokens_text_in_fresh + tokens_text_in_cached) / 1000000.0 * 4 AS text_cost_full_eq
FROM bridge_transactions
WHERE store_id = ? AND created_at >= NOW() - INTERVAL '30 days'
  AND model_variant IS NOT NULL
GROUP BY model_variant;

-- AHT 시계열
SELECT date_trunc('day', created_at) AS day,
       model_variant,
       AVG(call_duration_ms)/1000.0 AS aht_sec,
       COUNT(*) AS calls
FROM bridge_transactions
WHERE created_at >= NOW() - INTERVAL '30 days'
GROUP BY day, model_variant
ORDER BY day;
```

출처 (Sources)

1. OpenAI: Introducing gpt-realtime — full pricing
2. eesel.ai: GPT Realtime Mini pricing breakdown — mini pricing (검증 필요)

3. MarkTechPost: gpt-realtime-2 release — newest SKU info
4. Inference.net: OpenAI Rate Limits Guide — Tier ladder
5. Hamming AI: Voice Agent Testing Guide — A/B methodology
6. Forasoft: Realtime API Production Guide — production patterns
7. Synthflow: Vapi pricing breakdown — competitive context
8. CallSphere: AI Voice Agent Cost 2026 — market rate
9. **JM Tech One 라이브 데이터** (2026-05-08, callSid CA59d6f3f31..., CA47b6683b..., CA6eb23bf4...) — 실측 통화 10건

End of Report.

Distribution: founder + future investor materials. Next review: A/B Phase 1 결과 반영 후 (2026-05-22 예상).