OpenAI Realtime 3-Way 모델 전수 비교 + JM 적합도 점수

작성: 2026-05-08 · JM Tech One — Voice AI Pilot **비교 대상**: `gpt-realtime-2` (신규, 2026-05-08) · `gpt-realtime-1.5` (현재 사용) · `gpt-realtime-mini` **기준**: 라이브 통화 124s · 12.9 turns · 6,500-token system prompt · Marin voice · 5 언어 (EN/ES/KO/JA/ZH)

임원 요약 — 한 표로 보는 결론

항목	gpt-realtime-1.5 (현재)	gpt-realtime-2 (신규)	gpt-realtime-mini
JM 적합도 (0-50)	**43 / 50**	**42 / 50**	**34 / 50**
통화 1건 비용	$0.368	$0.371 (low effort)	$0.113
Audio 가격	$32 / $64 / 1M	**동일** ($32 / $64)	$10 / $20
Context window	32K	**128K (4×)**	32K
Tool calling	sequential (현재 silent 위험)	**parallel + audible preamble**	sequential
Big Bench Audio	81.4%	**96.6%**	미공개
TTFA (응답 시작)	~500ms	1.12s @ low	<500ms
1.5 → migration 비용	—	drop-in (reasoning.effort 추가만)	drop-in (품질 A/B 필요)
다국어 (KO/JA/ZH) 검증	라이브 사용 중	GPT-5-class 추정	보고된 약점
권장 사용처	**Pilot 안정 운영 (현재 default)**	**canary 검증 후 main 승격**	**English-only cafe A/B (3.5× 비용 절감)**

> **핵심 한 줄**: 2.0은 audio cost 동일 + 큰 context + parallel tools = **자연스러운 다음 default**. 1.5는 6-12개월 deprecation 예측. mini는 vertical 별 cost 옵션.

Part 1 — Master Spec Table

항목	gpt-realtime-2	gpt-realtime-1.5	gpt-realtime-mini
Status	GA (2026-05-08 발표)	GA (2025-08-28 snapshot)	GA
Snapshot	gpt-realtime-2	gpt-realtime-2025-08-28	gpt-realtime-mini
Context window	**128,000 tokens**	32,000 tokens	32,000 tokens
Max output	32,000	4,096	4,096
Modalities (in/out)	text + audio + image / text + audio	동일	동일
Voices	Marin, Cedar (+ legacy 8)	Marin, Cedar (+ legacy 8)	Marin/Cedar 공유 풀 (미문서화)
Audio formats	pcm16 24kHz, g711_ulaw, g711_alaw	동일	동일
VAD	server_vad + semantic_vad	동일	동일
Transports	WebRTC + WebSocket + SIP	동일	동일
Function calling	**parallel + async + 청취 가능 preamble**	sequential / async	sequential (parallel 미검증)
Reasoning effort	minimal / low / medium / high / xhigh (default: low)	n/a	n/a
Image input	Yes	Yes	Yes
MCP support	Yes	Yes	제한적
Big Bench Audio	**96.6% (high)**	81.4%	미공개
Audio MultiChallenge	**48.5% (xhigh)**	34.7%	미공개
Scale APR (instruction 유지)	**70.8%**	36.7%	미공개
TTFA (응답 시작)	1.12s @ low / 2.33s @ high	~500-800ms	<500ms
Knowledge cutoff	2024+ (GPT-5-class)	Sep 30, 2024	Oct 1, 2023
Tier 1 TPM/RPM	40K / 200	40K / 200	40K / 200
Tier 2 TPM/RPM	200K / 400	200K / 400	200K / 400

가격표 (per 1M tokens)

Token type	gpt-realtime-2	gpt-realtime-1.5	gpt-realtime-mini
Audio input	$32.00	$32.00	**$10.00**
Audio cached input	$0.40	$0.40	$0.30
Audio output	$64.00	$64.00	**$20.00**
Text input	$4.00	$4.00	$0.60
Text cached input	$0.40	$0.40	$0.06
Text output	$24.00 (+50%)	$16.00	$2.40
Image input	$5.00	$5.00	n/a

핵심 발견: 2.0의 **audio I/O는 1.5와 완전 동일**. 텍스트 출력만 +50% (reasoning trace 과금). 우리 통화 패턴에서 텍스트 출력은 ~1,200 tokens/call이라 비용 차이 미미.

Part 2 — 통화 1건 정확 비용 (3-way)

기준 데이터 (라이브 측정): - 평균 통화: 124s - 평균 turns: 12.9 - Audio in: 37,200 tokens (~62s × 600 t/s) - Audio out: 37,200 tokens - Text in (fresh): 16,770 tokens - Text in (cached): 67,080 tokens (80% hit ratio) - Text out: 1,200 tokens (tool calls + agent reasoning)

모델별 비용 분해

항목	gpt-realtime-1.5	gpt-realtime-2 (low)	gpt-realtime-mini
Text in fresh (16,770 × $4 / $4 / $0.60)	$0.067	$0.067	$0.010
Text in cached (67,080 × $0.40 / $0.40 / $0.06)	$0.027	$0.027	$0.004
Audio in (37,200 × $32 / $32 / $10)	$1.190	$1.190	$0.372
Audio out (37,200 × $64 / $64 / $20)	$2.381	$2.381	$0.744
Text out (1,200 × $16 / $24 / $2.40)	$0.019	$0.029	$0.003
Reasoning preamble overhead (2.0 only)	—	+$0.018	—
Subtotal (per 1M math)	$3.684	$3.712	$1.133
÷ 1000 = per call	**$0.368**	**$0.371**	**$0.113**
Twilio 추가 (2.07 min)	$0.037	$0.037	$0.037
All-in 통화 1건	**$0.405**	**$0.408**	**$0.150**
All-in 분당	**$0.196**	**$0.197**	**$0.072**

5매장 Pilot 월 비용

모델	월 통화 4,500	절감률
gpt-realtime-1.5 (현재)	$1,823	baseline
gpt-realtime-2.0	$1,836	+0.7% (무시할 수준)
gpt-realtime-mini	$675	**-63%** ($1,148 절감/월)

> **2.0 대 1.5는 비용 사실상 동일** — 비용은 결정 인자가 아님. 품질/안정성/migration 위험만 비교.

Part 3 — JM 적합도 점수 매트릭스 (0-5점, 10개 항목)

점수 기준

- **5점**: JM 요구사항 완벽 충족, 추가 작업 없이 사용 가능
- **4점**: 충족하지만 minor 검증/조정 필요
- **3점**: 사용 가능하지만 명확한 단점 존재
- **2점**: 큰 위험 또는 회귀 가능성
- **1점**: 사용 불가 (deal-breaker)
- **0점**: 미지원

종합 점수표

항목	gpt-realtime-1.5	gpt-realtime-2	gpt-realtime-mini
1. 비용 효율성	4	4	**5**
2. 음성 품질 (Marin)	**5**	**5**	4
3. 응답 latency (TTFA)	**5**	3	**5**
4. Tool calling (8 tools)	4	**5**	2
5. Long-context (6,500 prompt)	3	**5**	2
6. 다국어 (EN/ES/KO/JA/ZH)	4	4	2
7. 안정성 / Production 검증	**5**	3	3
8. Migration 비용 (1.5 기준)	**5** (no-op)	4	4
9. Pilot 진입 속도	**5**	4	3
10. Future-proofing (수명)	3	**5**	4
합계 (0-50)	**43**	**42**	**34**

Part 4 — 항목별 상세 점수 + 사유

1. 비용 효율성 (cost per call)

모델	점수	사유
1.5	**4**	$0.368/call. 시장 평균 $0.30+ 대비 적당. SMB 마진 1.7-2.8×
2.0	**4**	$0.371/call (실질 동일). +50% text-out은 우리 사용 패턴에서 +$0.01에 불과
mini	**5**	$0.113/call. 3.5× 저렴. 5,000매장 확장 시 연 $12.6M 절감

2. 음성 품질 (voice naturalness, Marin support)

모델	점수	사유
1.5	**5**	Marin 공식 지원. 라이브 운영에서 자연스러움 검증
2.0	**5**	Marin/Cedar 공식. GPT-5-class 표현력 향상
mini	**4**	"shared voice pool" 통해 Marin 사용 가능 (community 보고). 긴 응답에서 약간 평탄. 공식 문서에 voices 미명시

3. 응답 latency (TTFA — time to first audio)

모델	점수	사유
1.5	**5**	~500-800ms TTFA. 라이브 측정 TTFT 832-2504ms (call 따라 다름)
2.0	**3**	1.12s @ low effort (~600ms 더 느림). 2.33s @ high. **단**, parallel tool call 시 audible preamble로 체감 무음 감소
mini	**5**	<500ms 일관 보고. 모델 작아서 decoding 빠름

4. Tool calling (우리 8 tools 환경)

모델	점수	사유
1.5	**4**	8 tools 안정 작동 (라이브 검증). 단, sequential only — modify+recall 등 multi-step 시 latency 누적
2.0	**5**	**parallel + async + audible preamble** = "checking that for you" 발화 동시에 tool 실행. 우리 modify_order + recall_order 흐름 핵심 개선. Big Bench Audio 96.6%
mini	**2**	community 보고 8 tools 시 정확도 88-92% 저하. 우리 tool 수가 한계점 근처

5. Long-context handling (system prompt 6,500 tokens)

모델	점수	사유
1.5	**3**	32K context. 6,500 prompt + 12.9 turns × ~2,000 = 약 25K — **여유 7K**. INVARIANTS recency placement 등 fix 필요
2.0	**5**	**128K context**. 우리 prompt 무한 확장 가능. Scale APR 70.8% = repair/edit 견고
mini	**2**	32K + 미니 모델 → 6,500 prompt에서 drift 가능 (community 보고). 우리 INVARIANTS 룰 약화 위험

6. 다국어 fidelity (5개 언어)

모델	점수	사유
1.5	**4**	EN/ES Excellent, KO/JA/ZH Strong. 라이브 운영 검증. NATO recital 등 커스터마이징 가능
2.0	**4**	GPT-5-class — 언어 능력 향상 추정되나 **공식 KO/JA/ZH 벤치마크 부재**. 검증 필요
mini	**2**	영어/스페인어 strong. **KO/JA/ZH 약점 보고됨** — 고유명사 spelling, 성조 오류, 10턴+ 후 drift. KBBQ/Sushi/Chinese 매장 사용 위험

7. 안정성 / production 검증

모델	점수	사유
1.5	5	9개월 production 운영. Wave A.3 hardening 완료. 라이브 매장 검증
2.0	3	**2026-05-08 (어제) 출시**. production 데이터 1일 미만. 잠재 회귀 위험
mini	3	GA 상태이나 voice agent 사용 사례 적음. 가격 우선 selection 위험

8. Migration 비용 (1.5 기준)

모델	점수	사유
1.5	5	현재 default — migration 0
2.0	4	drop-in compatible. `reasoning.effort: "low"` 추가 + reasoning token 빌링 신규 변수. 코드 변경 ~5줄
mini	4	drop-in compatible. **품질 검증 A/B 필수** (KO/JA/ZH 등 회귀 위험)

9. Pilot 진입 속도

모델	점수	사유
1.5	5	이미 운영 중. retry fix만 추가하면 silent 해결
2.0	4	env var 변경 + canary 1매장으로 즉시 시작. parallel tool call이 silent agent 자연 해결
mini	3	A/B test 인프라 필요 (DB 컬럼, hash 분기, gate). 4-6주 소요

10. Future-proofing (모델 수명)

모델	점수	사유
1.5	3	OpenAI 패턴: 신규 모델 GA 후 6-12개월 내 deprecation 예상. 마이그레이션 부담 발생
2.0	5	최신 model — 향후 12-18개월 default. 즉시 채택 시 deprecation 사이클 1번 회피
mini	4	가격 옵션 라인 — 향후 mini-2.0 등 출시 가능하나 mini라인 자체는 유지 예상

Part 5 — 모델별 핵심 사용 시나리오 (recommendation)

1.5 → 즉시 안정 운영 default

언제: 지금 즉시. retry fix + Tier 2 도달까지. **근거**: - 안정성 5/5 - 라이브 매장 검증 완료 - migration 비용 0

액션: 1. ✅ rate_limit_exceeded retry 코드 추가 (이번 commit) 2. ✅ Tier 2 자동 승급 ($50 누적 spend 후)

2.0 → canary 1매장 즉시 시작

언제: retry fix 후 1주 이내 **근거**: - audio 비용 동일 - parallel tool calls = modify+recall 자연 개선 - 128K context = 향후 prompt 확장 여유 - Future-proofing 5/5

액션: 1. `OPENAI_REALTIME_MODEL=gpt-realtime-2` 환경변수로 canary 1매장 2. `reasoning.effort: "low"` 추가 3. AHT, TTFA, tool_call_success 측정 (1주) 4. Gate: 동일/우월하면 main으로 승격, 1.5는 fallback 유지

mini → English-only Cafe A/B (Phase 2)

언제: 1.5/2.0 안정화 후 (4-6주 후) **근거**: - 비용 5/5 (3.5× 저렴) - 영어/스페인어 매장에서 충분한 품질 - KBBQ/Sushi/Chinese에는 적합도 낮음

액션: 1. DB schema (model_variant 컬럼) 2. hash-based per-call 분기 (env var AB_MINI_PCT=10 → 50) 3. completed_order_rate ≥75%, tool_success ≥95% gate 4. **언어별 분기 정책 확정**: EN/ES → mini default, KO/JA/ZH → full 유지

Part 6 — 통합 권장 — 3-Phase 진화 전략

Phase 1: 즉시 안정 (이번 주)

- **모델**: 1.5 유지
- **변경**: retry fix 코드 commit + $50 충전
- **효과**: silent agent 무음 6-10s → 2s

Phase 2: 2.0 canary 검증 (다음 1-2주)

- **모델**: 1매장 → 2.0 canary
- **변경**: env var 변경 + reasoning.effort
- **메트릭**: AHT, TTFA, parallel tool call 작동 검증
- **결정 게이트**: 1주 후 모든 매장으로 확장 OR 1.5 유지

Phase 3: mini hybrid routing (1-2개월)

- **모델**: vertical/language별 분기
- **변경**: A/B 인프라 + store_configs.realtime_model_override
- **효과**: 영어/스페인어 매장에서 비용 3.5× 절감
- **펀드 narrative**: "language-tiered model routing for capital-efficient scaling"

Part 7 — Risks / Unknowns

항목	영향	검증 방법
2.0 KO/JA/ZH 품질 미검증	다국어 매장 회귀 가능	50-utterance per-language eval (canary)
2.0 reasoning token 빌링	통화 비용 +5-10% (low) ~ +30% (high)	low 고정 + usage 모니터링
2.0 TTFA 1.12s vs 1.5 500ms	첫 응답 600ms 늦음	parallel tool preamble로 체감 시간 감소 검증
mini Marin voice 품질	UX 약간 평탄	A/B 테스트 시 사용자 만족도 surrogate (cancel rate)
mini 8 tools 정확도	tool_call_failures ↑	A/B에서 실측
1.5 deprecation timeline 미발표	강제 migration 시점 불명	OpenAI 발표 모니터링
2.0 첫날 production 위험	미발견 회귀	canary 단일 매장 + 24시간 모니터링

Part 8 — 최종 권장 (한 줄)

단기 (이번 주): 1.5 + retry fix + Tier 2. **중기 (1-2주)**: 2.0 canary 1매장 (audio 비용 동일 + parallel tool calls = silent agent 자연 해결 + 향후 default). **장기 (1-2개월)**: 영어/스페인어 매장 mini hybrid routing (3.5× 비용 절감 펀드 narrative).
하지 말 것: 2.0을 모든 매장 즉시 전환 (안정성 3/5) / mini를 KO/JA/ZH 매장에 적용 (다국어 2/5) / 1.5에 안주 (deprecation 위험)

출처 (Sources)

1. TheNextWeb: OpenAI launches GPT-Realtime-2 (2026-05-08)
2. OpenAI API Docs: gpt-realtime-2
3. OpenAI API Docs: gpt-realtime-1.5
4. OpenAI API Docs: gpt-realtime-mini
5. OpenAI: Introducing gpt-realtime
6. DataCamp: GPT-Realtime-2 — GPT-5-class reasoning
7. Latent Space: GPT-Realtime-2 SOTA voice APIs
8. Latent Space: Realtime API Missing Manual
9. OpenAI API Pricing
10. Microsoft Learn: GPT Realtime API token rates
11. eesel.ai: GPT realtime mini practical guide
12. MarkTechPost: Three Realtime Audio Models 2026-05-08
13. **JM Tech One 라이브 데이터** (callSid CA59d6f3f31..., CA47b6683b..., CA6eb23bf4..., 2026-05-08) — 통화 10건 실측

End of Report.

Distribution: founder + technical due-diligence material. Next review: 2.0 canary 1주 결과 반영 시점.