OpenAI Realtime 모델 — 종합 리서치

gpt-realtime-1.5 vs gpt-realtime vs gpt-realtime-mini — JM Tech One 마이그레이션 최적 모델 선정

JM Tech One · 2026-05-05 · Internal Strategy Document

OpenAI Realtime 모델 — JM Tech One 마이그레이션 종합 리서치

날짜: 2026-05-05 | **분석:** smb-voice-agent-researcher | **대상:** JM Tech One 창업자 (2인 팀, 포틀랜드 본사) | **의사결정 컨텍스트:** Retell + Gemini 3.1 Flash Lite → OpenAI Realtime 직접 마이그레이션

요약 (Executive Summary)

2026-05-05 시점 OpenAI Realtime API는 세 모델로 정리됨: **`gpt-realtime-1.5`** (플래그십, 2026-02-23 출시), **`gpt-realtime`** (2025-08-28 GA), **`gpt-realtime-mini`** (저가 변형, 스냅샷 `2025-10-06` / `2025-12-15`). 레거시 `gpt-4o-realtime-preview*` 계열은 2025-09에 6개월 deprecation 통지 → 2026-03 종료(이미 지남). 가격은 풀 모델 audio in/out **$32/$64 per 1M**, mini는 약 **$10/$20 per 1M** (~3배 저렴)에서 안정화됨. JM Tech One의 단일 매장(JM Cafe) 파일럿 + 8개 voice tool + idempotent guard + Asian-SMB 확장 시나리오에 대해 권장: 프로덕션은 **`gpt-realtime-1.5`**, 카나리/회귀 테스트/rate-limit fallback은 **`gpt-realtime-mini`**. `gpt-4o-realtime-preview*` 사용 금지(deprecated). `gpt-realtime-2025-08-28` dated snapshot 신규 고정 비추천 — 1.5는 tool calling 신뢰도(+7% instruction following), 한국어/일본어/중국어 mid-utterance switching, alphanumeric transcription(+10.23%) 모두 측정 가능한 개선. 이 네 가지는 JM의 핵심 통증과 직결됨(레스토랑 주문 정확도 = tool 신뢰도; 전화번호/주문코드 = alphanumeric; 다국어 = Asian-SMB 웨지).

---

1. 모델 라인업 — 전수 인벤토리 (2026-05-05)

모델	스냅샷	출시일	상태	모달리티	컨텍스트	최대 출력	최대 세션
`gpt-realtime-1.5`	`gpt-realtime-1.5` (alias), Azure `2026-02-23`	2026-02-23	GA, 현행 플래그십	audio in/out, text, image in	32K (입력 ~28,672)	4,096	60분 (OpenAI) / 30분 (Azure EU)
`gpt-realtime`	`gpt-realtime-2025-08-28`, alias `gpt-realtime` (1.5로 floating 가능성)	2025-08-28 GA	GA, 직전 플래그십	audio in/out, text, image in	32K	4,096	60분
`gpt-realtime-mini`	`gpt-realtime-mini-2025-12-15`, `gpt-`	2025-10-06 / 2025-12-15	GA, 저가 변형	audio in/out, text	모델카드 128K / Realtime 세션 32K 유효	4,096	60분

모델	스냅샷	출시일	상태	모달리티	컨텍스트	최대 출력	최대 세션
	`realtime-mini-2025-10-06`						
`gpt-4o-realtime-preview-*`	`2024-10-01`, `2024-12-17`, `2025-06-03`	2024-10 → 2025-06	**Deprecated** (~2026-03 종료)	audio in/out, text	128K	4,096	30분
`gpt-4o-mini-realtime-preview-*`	`2024-12-17`	2024-12	**Deprecated** (상위 계열 동반)	audio in/out, text	128K	4,096	30분

음성 (gpt-realtime / 1.5): `marin`, `cedar` (2025-08 GA에서 신규, Realtime 전용), 레거시 `alloy`, `ash`, `ballad`, `coral`, `echo`, `sage`, `shimmer`, `verse`. Marin/Cedar이 OpenAI 포트폴리오 중 가장 자연스러움.

미공개 베타/ `gpt-realtime-2.0` / `gpt-realtime-pro` 는 2026-05-05 시점 Azure 모델 레지스트리, OpenAI changelog, 개발자 커뮤니티 어디서도 확인되지 않음. 존재한다면 비공개.

---

2. 가격 — 2026-05-05 권위 데이터

USD per 1M tokens. 토큰 환산: **사용자 audio = 1 token / 100ms** (분당 600), **어시스턴트 audio = 1 token / 50ms** (분당 1,200).

모델	Audio in	Audio out	Audio cached in	Text in	Text out	Text cached in
`gpt-realtime-1.5`	$32.00	$64.00	$0.40	$4.00	$16.00	$0.40
`gpt-realtime` (2025-08-28)	$32.00	$64.00	$0.40	$4.00	$16.00	$0.40
`gpt-realtime-mini`	$10.00	$20.00	$0.30	$0.60	$2.40	$0.06
`gpt-4o-realtime-preview-2025-06-03` (deprecated)	$40.00	$80.00	$2.50	$5.00	$20.00	$2.50
`gpt-4o-mini-realtime-preview` (deprecated)	$10.00	$20.00	$0.30	$0.60	$2.40	$0.30

5분 통화, 80/20 비율 (고객 4분 / 에이전트 1분):

- 입력: 4분 × 600 = 2,400 토큰 / 출력: 1분 × 1,200 = 1,200 토큰
- gpt-realtime-1.5: (2,400×$32 + 1,200×$64) / 1M = **$0.1536** ≈ **$0.031/분**
- gpt-realtime-mini: (2,400×$10 + 1,200×$20) / 1M = **$0.048** ≈ **$0.0096/분**
- gpt-4o-realtime-preview 레거시: ~$0.038/분 (deprecated)

캐싱 효과: 시스템 프롬프트 + tool 스키마(약 5K 토큰)를 적극 캐싱하면 입력 비용 80배 감소($32 → $0.40). 실효 정적 비용은 통화당 무시 수준.

---

3. 능력 비교 (1.5 vs GA vs mini)

능력	gpt-realtime-1.5	gpt-realtime (08-28)	gpt-realtime-mini
Function calling — ComplexFuncBench Audio	별도 미공개; GA 대비 instruction-following +7%	66.5% (직전 모델 49.7%)	미공개; 플래그십 미달
Async function calling	가능 (세션 흐름 유지)	가능	가능
Parallel tool calls	가능	가능	가능
Image input	가능	가능	불가
MCP 서버 연결	가능	가능	가능
Semantic VAD (eagerness 파라미터)	가능	가능	가능
Server VAD (레거시)	가능	가능 (일부 스냅샷에서 tool use와 충돌 보고됨)	가능
SIP 지원	가능 (2026 전용 SIP IP 추가)	가능	가능
WebRTC / WebSocket	둘 다	둘 다	둘 다
음성	Marin, Cedar + 레거시 8종	동일	부분 (Marin/Cedar 일관성 떨어짐)
다국어 mid-utterance switching	GA 대비 향상; 명시 기능	가능; 1.5보다 약함	가장 약함
Big Bench Audio reasoning	GA 대비 +5%	기준	GA 미만
Alphanumeric 인식	GA 대비 +10.23% (전화번호, 주문 코드)	기준	약함 — 전화번호/주문번호 캡처 시 위험
EU 데이터 거주성	가능 (`gpt-4o-realtime-preview-2025-06-03` 도)	가능 (`2025-08-28` 만)	부분
HIPAA BAA (audio in/out)	2026 Q1 시점 정식 등재 안 됨 — **법무 검토 필요**	동일 caveat	동일 caveat
Zero Data Retention (ZDR)	Trust Center 신청 가능; `store=false` + WebSocket 호환	동일	동일

---

4. 지연시간, Rate Limit, 운영 한도

- **TTFT / 첫 오디오 청크:** Realtime 계열은 ~250–300ms TTFT. 1.5는 점진적 개선 — 공개 TTFT 회귀 없음. Sendbird "interruption 처리 탁월", Genspark "통화 에러 절반 감소, connection rate 66%로 두 배" 보고.
- **Rate limit (Tier 1):** ~200 RPM, ~40K TPM. Realtime 세션은 별도 회계 (concurrent session 수가 결정적). Tier 5는 ~20K RPM, 15M TPM.
- **동시 Realtime 세션:** 공식적으로 API 키당 ~100 soft cap (커뮤니티 보고). 일부 개발자는 500+ 세션 열림. **100을 hard로 가정, 5매장 SLA 전 stress test 필수.**
- **최대 세션 길이:** OpenAI 60분 / Azure EU 30분. JM Cafe 통화 통상 5분 미만 — 비제약.
- **컨텍스트:** 32K 토큰, 입력 ~28,672. 긴 통화는 클라이언트 측 요약 필요; Realtime API는 자동 압축 안 함.
- **알려진 이슈:**
- 일부 스냅샷에서 server VAD가 tool use를 깨뜨림 (2026 Q1 보고) — semantic VAD 권장.
- `gpt-realtime-2025-08-28`에서 transcript 누출 버그 보고 — 해당 dated snapshot 고정 비추천.
- 다국어: 프랑스어/억양 영어 약함; 한/일/중은 양호하나 완벽하지 않음 — 프롬프트 anchoring 필수.

---

5. 다국어 현실 점검

OpenAI는 57개+ 언어 지원을 명시하나 WER <50% 통과 언어만 "지원"으로 표기. JM의 Asian-SMB 확장 관점:

언어	gpt-realtime-1.5	gpt-realtime GA	mini	주의
영어	우수	우수	우수	네이티브
스페인어	매우 양호 (alphanumeric 향상)	매우 양호	양호	PDX Hispanic 시장 가능
한국어	양호 — 1.5 switching 향상	사용 가능	가장 약함	프롬프트로 한국어 anchoring 필수
일본어	양호	사용 가능	가장 약함	동일
중국어 (Mandarin)	양호	사용 가능	가장 약함	성조 양호; 관용어 자연스러움 부족
프랑스어	가장 약함	가장 약함	가장 약함	현재 회피

Mid-call language switching ("English ↔ Korean ↔ English")은 1.5의 핵심 개선이며 GA 대비 명확히 우수. mini는 의미 있게 떨어짐 — 다국어 매장에 prompt 가드레일 없이 mini 배포 금지.

---

6. 점수 매트릭스 — JM 의사결정 요소

10점 만점. 가중치는 JM 우선순위 반영: 단일 매장 단계에서 비용은 실재하나 지배적이지 않음; tool 신뢰도 = 존재 위협; 다국어 = Asian-SMB 웨지.

가중치: 비용 20%, 지연시간(TTFT/barge-in) 20%, 다국어 switching 25%, Tool/기능 호환성 35%.

모델	비용 (20%)	지연 (20%)	다국어 (25%)	Tool/기능 (35%)	가중 합계
`gpt-realtime-1.5`	7 / 10	9 / 10	9 / 10	10 / 10	**(7×0.20)+(9×0.20)+(9×0.25)+(10×0.35) = 1.4+1.8+2.25+3.5 = 8.95**
`gpt-realtime` (08-28)	7 / 10	8 / 10	7 / 10	9 / 10	**(7×0.20)+(8×0.20)+(7×0.25)+(9×0.35) = 1.4+1.6+1.75+3.15 = 7.90**
`gpt-realtime-mini`	10 / 10	8 / 10	5 / 10	7 / 10	**(10×0.20)+(8×0.20)+(5×0.25)+(7×0.35) = 2.0+1.6+1.25+2.45 = 7.30**
`gpt-4o-realtime-preview-2025-06-03`	4 / 10	7 / 10	6 / 10	6 / 10	**(4×0.20)+(7×0.20)+(6×0.25)+(6×0.35) = 0.8+1.4+1.5+2.1 = 5.80**
`gpt-4o-mini-realtime-preview`	9 / 10	7 / 10	4 / 10	5 / 10	**(9×0.20)+(7×0.20)+(4×0.25)+(5×0.35) = 1.8+1.4+1.0+1.75 = 5.95**

최종 우승: `gpt-realtime-1.5` 8.95/10. Mini 7.30이 최강 fallback. gpt-4o 레거시 두 변형은 dominated + deprecated — 제외.

---

7. 시나리오별 추천

기준 통화량: 5매장 × 50통화/일 × 5분 × 30일 = 37,500분/월.

시나리오 A — 단일 매장 영어 중심 파일럿 (오늘의 JM Cafe)

- **추천: `gpt-realtime-1.5`** (해당 region에서 미가용 시 alias `gpt-realtime`).
- 1매장 월 비용 (7,500분): ~$0.031/분 × 7,500 = **~$232/월** (캐싱 전). 캐싱 적용 시 $180–$200.
- 이유: 레스토랑 주문 정확도 = 존재 위협. mini와의 비용 차이($72/월)는 1매장 단계에서 function-calling 회귀를 정당화 못 함.

시나리오 B — PDX 5매장 확장, Hispanic 비율 高

- **추천: 5매장 모두 `gpt-realtime-1.5`.** 1.5 스페인어는 "매우 양호" + alphanumeric 강 — 스페인어 전화번호 캡처 중요.
- 월 비용: ~$232 × 5 = **~$1,160/월** raw; 캐싱 시 **~$700–$900/월**.
- 이 단계에서 hybrid 비추천 — 운영 복잡도 > 절감액.

시나리오 C — Asian-SMB 확장 (한식/일식/중식)

- **추천: `gpt-realtime-1.5` 만, 타협 없음.** Mini 다국어 = 최약체, 한국어 웨지 직접 훼손.
- 시스템 프롬프트에 매장 주 언어 명시적 anchoring + `respond_in_language` 지시; 사용자 명시 요청 시에만 switching.
- 월 비용: B와 동일 (볼륨 스케일 전).

시나리오 D — 시간당 100통화 스케일

- **추천: `gpt-realtime-1.5` 주 + `gpt-realtime-mini` 오버플로우 라우터.** 통화 시작 시 (caller-ID + 첫 발화 의도 분류기를 text-only Gemini 3.1 Flash Lite 또는 mini로) 의도 사전 분류 → FAQ/영업시간/메뉴 조회 = mini, 예약/주문/결제 = 1.5.
- Hybrid ROI: 40%가 mini로 라우팅되면 blended cost $0.031/분 → ~$0.022/분 (~30% 절감). 100 통화/시간 × 8시간 × 5분 = 4,000분/일 = 120K분/월, 절감 ~$1,080/월.
- 운영 caveat: hybrid는 fail-mode 2개 추가(라우터 오류, mini→플래그십 핸드오프). 5매장에서 1.5-only가 안정된 후에만 구축.

Hybrid mini ↔ 플래그십 라우팅 — 활성화 조건

- 볼륨 임계: >50K분/월 (5매장 유기적 성장 초과).
- 라우팅 신호: 첫 2초 오디오 의도 분류기 + caller history.
- Fallback: mini의 function-call 신뢰도가 임계치 미만이면 1.5로 mid-session hot-swap (현 API의 `session.update`로 모델 swap 가능).

---

8. 마이그레이션 의사결정 트리

```
POC (Week 0–2): gpt-realtime-mini
  → 이유: 가장 싸게 fail-fast (WebRTC/SIP, Twilio TCR, 오디오 패스스루,
    idempotent guard 검증). 전송 버그를 잡는 동안 tool 품질 차이는 병목 아님.

회귀 테스트 (Week 2–4): gpt-realtime-1.5
  → 이유: 기존 Retell+Gemini 통화 코퍼스 replay. 1.5가 production target —
    실제 ship할 모델 대비 회귀 diff 측정.

카나리 (Week 4–6): gpt-realtime-1.5 (5–10% 트래픽)
  → 이유: 프로덕션 모델과 동일해야 카나리 신호 명확.
  → 행동 surprise로 rollback isolation 필요할 때만 dated snapshot 핀; 그 외엔
    floating alias `gpt-realtime-1.5` 사용.

풀 프로덕션 (Week 6+): gpt-realtime-1.5 (floating alias)
  → 이유: floating alias는 향후 개선(`gpt-realtime-1.6`, `2.0`) 자동 수령.
    OpenAI deprecation cadence가 6개월로 안정적 — 허용 가능 위험.
  → daily smoke-test로 drift 감지.

Rate-limit / 429 Fallback: gpt-realtime-mini
  → 이유: 3배 저렴, Realtime 세션 프로토콜 동일, drop-in 호환. 품질 저하는
    가시적이나 통화는 완료됨.
  → Realtime 클라이언트 측 retry + model swap으로 구현; mini를 silent 서빙
    금지 (반드시 로깅).

개발/테스트 비용 최적화: gpt-realtime-mini
  → 이유: 비고객 테스트 ~70% 저렴. 프로덕션 테스트는 여전히 1.5.
```

---

9. JM 스택 통합 훅

- **Tool 스키마 캐싱:** 8개 voice tool (`create_order`, `modify_order`, `cancel_order`, `make_reservation`, `modify_reservation`, `cancel_reservation`, `allergen_lookup`, `recall_order`)을 세션 시작 시 안정적 ID로 1회 정의. 캐시 입력 $0.40/M에서 통화당 tool 재주입 비용 무시 가능.
- **Idempotent guard:** OpenAI Realtime에 변경 불필요 — function call의 `call_id` semantics 보존. 현재 idempotency 레이어 (RLS-tenanted `tenant_id` + tool args hash dedup key) 그대로 유지.
- **RLS 격리:** `tenant_id`를 세션 스코프 변수로 전달; 모델에 노출 금지. 모든 tool 호출에서 서버 측 강제 (현 패턴).
- **Semantic VAD `eagerness=low`:** 예약 read-back 등 긴 어시스턴트 턴에서 조기 interruption 감소.
- **Twilio TCR + SIP:** OpenAI가 2026에 전용 SIP IP 범위 추가 (`sip.api.openai.com` GeoIP 라우팅) — PSTN 지연 최소화 위해 WebRTC 브릿징보다 직접 SIP 권장.
- **음성 선택:** `marin`은 영어 기본 매장(따뜻함); `cedar`는 활발한/젊은 demo. 한국어 자연스러움은 두 음성 모두 테스트 필요 — 커뮤니티 보고 엇갈림.
- **Allergen tool (Tier 3 EpiPen 핸드오프):** 1.5의 향상된 instruction-following이 Tier 3 hard-stop을 보존하는지 카나리 acceptance gate에 추가.

---

10. 리스크 & 워치리스트

1. **HIPAA 갭:** OpenAI Realtime audio in/out은 2026 Q1 Azure 명확화 기준 정식 BAA 범위 미포함. 레스토랑 스코프는 PHI 미발생이나 향후 약국/클리닉 인접 vertical 진입 시 재평가.
2. **Transcript 누출 버그** in `gpt-realtime-2025-08-28` — 해당 정확 snapshot 핀 회피. floating `gpt-realtime` 또는 `gpt-realtime-1.5` 직행.
3. **Server VAD ↔ tool use 충돌** in 일부 snapshot — JM tool surface는 semantic VAD 기본.
4. **동시 세션 ceiling** 모호 — 5매장 rollout SLA 약속 전 load-test 확정.
5. **Floating alias drift** — 향후 모델 bump (예: 1.6)이 JM tool 패턴에 회귀할 수 있음. daily smoke-test로 완화; 분기별 snapshot 핀 검토.
6. **Mini의 한국어/일본어 품질** — 부하 시에도 Asian-SMB 통화를 mini로 라우팅하지 말 것; 플래그십 429 retry 우선.

---

11. 출처

1. OpenAI — Introducing gpt-realtime — GA 발표, 2025-08-28; 가격, ComplexFuncBench 66.5%, Marin/Cedar 음성.
2. OpenAI Platform — gpt-realtime model card — 스냅샷, 모달리티.
3. OpenAI Platform — gpt-realtime-mini model card — 컨텍스트, 모달리티, cost tier.
4. OpenAI Developers — gpt-realtime-1.5 model card — 1.5 스펙.
5. Perplexity — OpenAI releases gpt-realtime-1.5 for voice AI developers — 2026-02-23 출시 확인; +7% instruction-following, +10.23% alphanumeric, +5% Big Bench Audio.
6. OpenAI API Pricing — 권위 가격.
7. Azure OpenAI Foundry — model availability — 2025-08-28, 2025-10-06, 2025-12-15, 2026-02-23 버전 확인.

8. OpenAI Developers — Deprecations — gpt-4o-realtime-preview deprecation.
9. OpenAI Realtime VAD guide — semantic VAD eagerness.
10. OpenAI Developer Community — gpt-realtime-2025-08-28 transcript leakage bug — 알려진 이슈.
11. OpenAI Developer Community — Realtime languages — 57+ 언어 리스트, 정확도 노트.
12. OpenAI Developer Community — multilingual challenges — 프랑스어 약점, language drift.
13. Sprinklr — Benchmarking gpt-realtime — 독립 음성 에이전트 벤치.
14. InfoQ — gpt-realtime production-ready — 기능 분석.
15. Microsoft Q&A — HIPAA eligibility of Realtime audio — 2026 시점 HIPAA 갭.
16. Microsoft Q&A — Realtime 30-min session — Azure EU 세션 ceiling.
17. GitHub — openai/openai-realtime-agents issue #119 — 세션 길이 관리 패턴.
18. Forasoft — Realtime API WebRTC/SIP/WebSocket integration — 전송 매트릭스.
19. eesel — gpt-realtime-mini pricing — 독립 분당 분석.
20. Hacker News — GPT-Realtime-1.5 Released — 1.5 신뢰도 커뮤니티 신호.